



Inteligência Computacional: atividade 02

Diretrizes: As questões devem ser resolvidas manualmente. O nome do arquivo de envio com as soluções deve seguir o formato: IC_2026_2_NOME_MATRICULA.pdf

1) Considerando o conjunto de treino a seguir da Tabela 1 com oito instâncias, cada uma definida por um vetor de entrada $\mathbf{x}_i \in \mathbb{R}^4$ de atributos e y uma variável categórica, de tal modo que $\{A, B, C\} \in y$ representa a classe associada à instância.

Tabela 1: Conjunto de dados para treino questão (1)

#	x_1	x_2	x_3	x_4	y
1	7	-3.2	4.7	1.4	B
2	6.4	3.2	-4.5	1.5	B
3	4.3	-4	1	0.1	A
4	4	3	-1.6	0.2	B
5	1.3	1.9	5.6	1.8	C
6	5.1	8.4	9	7	A
7	3.3	2.9	-2.6	4.8	C
8	-2.3	5.6	-7	6	B

a) Projete um classificador *k-nearest neighbor* com $k = 1$, e classifique o conjunto de dados de teste, definido na Tabela 2, considerando a distância **Euclidiana**. Informe o erro do classificador.

Tabela 2: Conjunto de dados para teste para a questão (1)

#	x_1	x_2	x_3	x_4	$\hat{y}$	y
1	-1.5	3.1	-5	4	?	A
2	3.4	-8.4	2	-6	?	B
3	-5.2	1.3	2	3	?	B
4	8.1	0.4	-12	-4	?	C
5	2.1	3.4	-8	-2	?	C

b) Assumindo $k = 3$, houve diferença na quantidade de erros do classificador? A performance melhorou ou piorou, por quê? Em caso de empate, considere uma escolha aleatória.

2) Considerando que as 11 primeiras instâncias da Tabela 3 são destinadas ao treino, cada uma definida por um vetor de entrada $\mathbf{x}_i \in \mathbb{R}^4$ de atributos e y uma variável categórica, de tal modo que $\{A, B, C\} \in y$ representa a classe associada à instância. Projete um classificador *k-NN* adotando a distância de **Hamming**, levando em conta que o valor de k é o único hiperparâmetro a ser otimizado. Quantize os atributos do vetor de entrada $\mathbf{x}_i$ dos conjuntos de treino e teste usando apenas 1 bit, de forma que o valor quantizado de x , $x \in \mathbf{x}_i$, seja 1 se x for positivo ou 0 caso contrário.

Além disso, considere que as últimas 5 instâncias do conjunto da Tabela 3 são para validação, de modo a usá-lo para escolher o melhor valor de k , de acordo com o desempenho nesse conjunto. Nesse sentido, considere que k pode ser 1 ou 3. Informe o valor de k escolhido e o erro que o classificador obteve no conjunto de teste definido na Tabela 4.

Tabela 3: Conjunto de dados para treino e validação da questão (2)

#	x_1	x_2	x_3	x_4	y
1	4	-5.2	4.7	1.4	B
2	2.3	4.2	-4.5	2.5	C
3	7.5	-4	1.1	3.1	A
4	5	3	-1.6	1.2	B
5	3.5	2.9	5.6	1.8	B
6	7.1	-10.4	9.2	7	A
7	6.3	2.9	-3.6	4.8	C
8	-6.3	2.8	-7	8	B
9.3	-1.5	5.4	-5.5	1.8	A
10	3.4	-2.4	3.1	-6.9	C
11	-5.2	6.8	7.4	3.1	B
12	2.1	1.8	-4	9.5	A
13	3.2	8.4	-9.2	-2	C
14	8.2	0.3	3.2	6.6	B
15	-4.7	-1.2	-5	-5.2	A
16	-2.7	3.4	-5.9	-1.6	A

Tabela 4: Conjunto de dados para teste da questão (2)

#	x_1	x_2	x_3	x_4	$\hat{y}$	y
1	-1.5	3.4	-5	1	?	B
2	3.4	-2.4	2	-6	?	C
3	-5.2	5.3	7	3	?	A
4	2.1	1.8	-4	-9	?	C
5	-4.7	0.4	-12	-2	?	A

3) A entrada de um classificador SVM não-linear consiste no vetor $\mathbf{x} = [x_1, x_2, x_3, x_4]$ com quatro atributos. A classe y pode ser 0 ou 1. A função de decisão dessa SVM é dada por $f(\mathbf{x}) = 4\mathcal{K}(\mathbf{x}; [2, -3, 4, 7]) - 5\mathcal{K}(\mathbf{x}; [1, 5, 3, 0]) + 2$. O kernel $\mathcal{K}(\mathbf{x}; \mathbf{z}) = \langle \mathbf{x}, \mathbf{z} \rangle^2$ é polinomial de ordem 2. Assumindo-se uma entrada $\mathbf{x} = [1, 5, 6, 0]$, quais são os valores de: **a)** $f(\mathbf{x})$ e **b)** da classe estimada $\hat{y}$?

4) Execute uma única iteração de agrupamento com K -Means, adotando a distância Euclidiana e $K = 3$. Os dados de entrada consistem em seis vetores bidimensionais armazenados em uma matriz 2×6 dada por $A = \text{numpy.array}([[2, 3, 0, 1, 2, 4], [0, 1, 2, 0, 3, 2]])$ em notação do Python. Por exemplo, o primeiro exemplo é $\mathbf{x}_1 = [2, 0]^\top$, enquanto o segundo exemplo é $\mathbf{x}_2 = [3, 1]^\top$. Dado que a distância entre o exemplo i , com $i = 0, 2, \dots, 5$, e a centróide j , com $j = 0, 1$ ou 2 , já foi computada e armazenada no elemento $D[i, j]$ de uma matriz $D = \text{numpy.array}([[7, 2, 4], [2, 24, 1], [49, 4, 3], [1, 3, 3], [7, 3, 2], [3, 5, 6]])$ de dimensão 6×3 , quais são as novas três centróides?

5) Dado o dataset da tabela abaixo, com 4 exemplos e 3 parâmetros no vetor de entrada $\mathbf{x}'$, deseja-se aplicar PCA para reduzir a dimensão da entrada para apenas 2 parâmetros.

A matriz de PCA (com as componentes principais) calculada por SVD é:

$$\mathbf{P} = \begin{bmatrix} 1 & 4 & 3 \\ 2 & 3 & 3 \\ 5 & 1 & -2 \end{bmatrix}.$$

#	x_1	x_2	x_3	y
1	2	3	3	0
7	1	5	2	1
5	4	-1	4	1
4	2	4	10	1

A matriz $\mathbf{P}$ pode ser usada para gerar o vetor $\mathbf{z} = \mathbf{P}\mathbf{x}$, onde $\mathbf{x}$ é o vetor coluna representando um exemplo. Crie uma nova tabela com o novo conjunto de dados, contendo apenas os dois parâmetros de entrada fornecidos pelo PCA.

6) Dado o conjunto de treino da tabela abaixo, projete uma árvore de decisão, crescendo tanto quanto permitido, com o objetivo de alcançar a situação ideal em que todas as folhas tenham zero de impureza. Mas respeite uma profundidade máxima de 2 (ou seja, no máximo 4 folhas). Como medida de impureza, é adotado o critério de Gini dado por $G_k = 1 - \sum_{i=1}^C p_i^2$, onde k é o nó em questão, p_i é a probabilidade da classe i no nó k e C é o número total de classes.

#	x_1	x_2	y
1	12	4.2	0
2	9	1.5	1
3	13	2.4	0
4	5	2.4	0
5	4	1.5	1
6	10	1.2	1
7	11	1.5	0

7) Um modelo de classificação binária foi aplicado a um conjunto de 1000 amostras para detectar uma doença rara. A matriz de confusão obtida foi:

Tabela 5: Matriz de confusão para o classificador

	Classe 0	Classe 1
Classe 0	40	10
Classe 1	90	860

Dada a matriz de confusão, calcule a) a acurácia do modelo, b) a precisão e o recall, c) o F1-score.