Homework sobre Aprendizado Bayesiano

Inteligência Computacional - UFPA

Orientações gerais

Faça as resoluções de forma manuscrita e descreva com detalhes suficientes os passos matemáticos usados. Software pode ser utilizado para auxiliar os cálculos, mas os resultados relevantes devem ser transpostos para a resolução e explicados. Salvo indicação em contrário, duas casas decimais são suficientes.
Para as questões com Gaussianas, use as estimativas de máxima verossimilhança calculadas no conjunto de treino:

$$\hat{\mu} = \frac{1}{N}\sum_{i=1}^{N} x_i, \qquad \hat{\sigma}^2 = \frac{1}{N}\sum_{i=1}^{N}(x_i - \hat{\mu})^2.$$

Para o Bernoulli Naïve Bayes, use suavização de Laplace com $\alpha = 1$, a menos que a questão indique explicitamente outra configuração. Considere as probabilidades *prior* estimadas pelas frequências das classes no conjunto de treino.

Conjuntos de dados

Os mesmos conjuntos são utilizados ao longo das questões. Cada linha tem a forma (x_1, x_2, x_3, y), com três *features* e classe $y \in \{0, 1, 2\}$.

Treino

x_1	x_2	x_3	y
2000	4	-6	0
3000	3	-4	0
5000	5	3	1
-1000	-4	2	1
-2000	0	5	1
400	5	40	2
50	6	30	2
45	3	20	2

Validação

x_1	x_2	x_3	y
0	-2	-3	0
3000	-4	-2	0
-1000	0	2	1
60	2	20	2

Teste

x_1	x_2	x_3	y
1000	2	-3	0
-2000	4	-6	1
-1000	5	20	2

Parte I - Fundamentos de Probabilidade

Questão 1 – PMF e PDF

Considere uma variável aleatória discreta, com função de massa de probabilidade $p_X(x)$ (PMF), e uma variável aleatória contínua, com função densidade de probabilidade $f_X(x)$ (PDF). Discuta os seguintes aspectos:

a) como cada função representa probabilidades: diretamente ou por meio de soma/integração;
b) quais valores são permitidos para $p_X(x)$ e $f_X(x)$ em um ponto arbitrário x;
c) se $p_X(x)$ pode ser maior que 1 e se $f_X(x)$ pode ser maior que 1. Justifique.

Questão 2 – Aplicação do teorema de Bayes

Você trabalha para uma empresa de seguro de automóvel e deve analisar o seguinte perfil. Suponha que um motorista que estaciona o veículo na rua tenha probabilidade de sinistro

$$P(S \mid E) = \frac{1}{6} \approx 16{,}67\%.$$

Além disso, considere $P(S) = 0{,}2$ e $P(E) = 0{,}6$.
Calcule a probabilidade de o carro estar estacionado na rua dado que ocorreu um sinistro, isto é, $P(E \mid S)$.

Questão 3 – Bayes com variável contínua e classe discreta

Deduza o teorema de Bayes a partir da definição de probabilidade condicional para o caso em que Y é uma variável aleatória discreta (por exemplo, a classe 0, 1 ou 2 de um classificador) e X é uma variável aleatória contínua com densidade $f_X(x)$.
Mostre que, para uma classe y e um valor contínuo x,

$$P(Y = y \mid X = x) = \frac{f_{X|Y}(x \mid y)\, P(Y = y)}{f_X(x)},$$

onde $f_{X|Y}(x \mid y)$ é a densidade condicional de X dada a classe $Y = y$.
Como leitura complementar, consulte: https://stats.stackexchange.com/questions/448020/does-bayes-theorem-apply-to-joint-distributions-of-discrete-and-continuous-rando

Questão 4 – Marginalização discreta

Considere a distribuição conjunta apresentada abaixo. Marginalize a variável c para obter $P(a, b)$ e determine os valores indicados por "?".

Distribuição conjunta

a	b	c	$P(a,b,c)$
0	0	0	0.1
0	0	1	0.2
1	0	0	0.4
1	1	0	0.1
1	1	1	0.2

$\Longrightarrow$

Marginal

a	b	$P(a,b)$
0	0	0.3
1	0	?
1	1	?

Questão 5 – Marginalização contínua

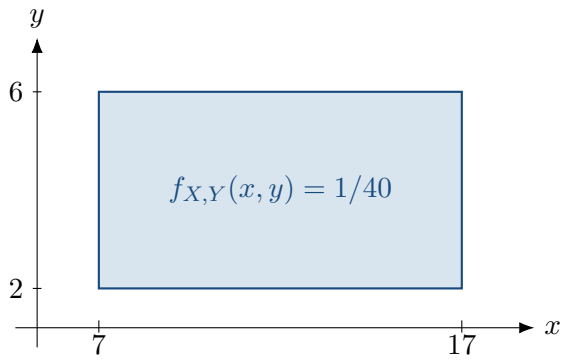
Considere a PDF conjunta

$$f_{X,Y}(x,y) = \frac{1}{40} = 0{,}025$$

para $7 \le x \le 17$ e $2 \le y \le 6$, e zero fora dessa região.

a) Encontre as expressões analíticas das marginais $f_X(x)$ e $f_Y(y)$, indicando também seus suportes.

b) Desenhe os gráficos de $f_X(x)$ e $f_Y(y)$.



Parte II - Classificadores Bayesianos

Questão 6 – Classificador Gaussiano unidimensional

Projete um classificador estatístico de Bayes usando uma densidade Gaussiana para modelar cada uma das três classes do conjunto de treino, mas considere somente a primeira *feature* x_1. Usando as estimativas de média e variância definidas nas orientações iniciais, determine:

a) as probabilidades *prior* das três classes;

b) os parâmetros das densidades condicionais $f_{X_1|Y}(x \mid y)$ para $y \in \{0, 1, 2\}$;

c) para uma entrada $x_1 = 2$, as probabilidades posteriores $P(Y = y \mid X_1 = 2)$ e a classe predita.

Questão 7 – Gaussian Naïve Bayes em três dimensões

Projete agora o classificador com as três *features* (x_1, x_2, x_3), assumindo independência condicional entre elas dada a classe (Naïve Bayes). Classifique todos os exemplos do conjunto de teste e informe: (a) a classe predita para cada exemplo e (b) o erro de classificação.

É recomendado usar um pequeno script. Se utilizar `sklearn.naive_bayes.GaussianNB`, mantenha as *priors* empíricas e registre qualquer diferença numérica relevante causada pelo tratamento interno das variâncias.

Questão 8 – Bernoulli Naïve Bayes - cálculo manual

Use o classificador `BernoulliNB` com limiar $t = 1$ para binarizar cada *feature*:

$$z_j = \begin{cases} 1, & x_j > 1, \\ 0, & x_j \le 1, \end{cases} \qquad \alpha = 1.$$

Treine o modelo com o conjunto de treino. Para o primeiro exemplo, $x = (2000, 4, -6)$, calcule manualmente as probabilidades posteriores das três classes após a binarização e compare-as com `predict_proba`. Comente as concordâncias ou discrepâncias e use, no cálculo manual e no software, a mesma regra de binarização e o mesmo α.

Documentação: https://scikit-learn.org/stable/modules/naive_bayes.html

Questão 9 – Seleção do limiar no Bernoulli Naïve Bayes

Treine um classificador Bernoulli Naïve Bayes para o conjunto de treino. Escolha um único limiar t para binarizar todas as três *features*, testando as opções

$$t \in \{-1, 0, 1, 2\}.$$

Para cada limiar, use a regra $z_j = 1$ se $x_j > t$ e $z_j = 0$ caso contrário, sempre com suavização de Laplace $\alpha = 1$.
Use o conjunto de validação exclusivamente para selecionar o melhor limiar. Depois de escolhê-lo, mantenha essa configuração, ajuste o classificador usando o conjunto de treino e avalie o desempenho no conjunto de teste. Informe o limiar escolhido, as classes preditas e o erro no teste.

Questão 10 – Generalização

Na questão anterior, o conjunto de teste contém apenas três exemplos. O erro observado nesse conjunto é uma boa estimativa da capacidade de generalização do classificador? Explique, discutindo o efeito do tamanho da amostra de teste e a incerteza associada à estimativa do erro.

Parte III - Erro de Bayes e Redes Bayesianas

Questão 11 – Erro de Bayes - desafio

Considere um classificador $y = f(x)$ em que $x \in \mathbb{R}$ e $y \in \{0, 1\}$. As probabilidades *prior* são uniformes:

$$P(y = 0) = P(y = 1) = 0{,}5.$$

As densidades condicionais corretas dadas pela natureza são

$$X \mid y = 0 \sim U(3, 6), \qquad X \mid y = 1 \sim U(4, 10).$$

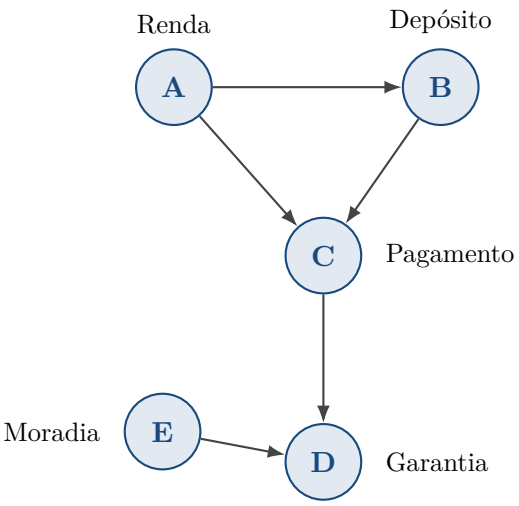
Determine:
a) a probabilidade mínima de erro $P(E)$, isto é, o erro de Bayes;
b) o classificador de Bayes ótimo e uma forma simples de representá-lo como regra de decisão.
Dica. Como as *priors* são iguais, compare as *likelihoods* nas regiões dos respectivos suportes. O erro pode ser escrito como

$$P(E) = P(y = 0)P(E \mid y = 0) + P(y = 1)P(E \mid y = 1).$$

No intervalo de sobreposição, observe qual das duas densidades uniformes é maior. Uma representação por *decision stump* com limiar em $x = 6$ pode ser obtida a partir dessa comparação.
Leitura complementar: https://en.wikipedia.org/wiki/Bayes_error_rate

Questão 12 – Rede Bayesiana

Uma rede Bayesiana representa dependências probabilísticas por meio de um grafo acíclico dirigido. Considere a rede abaixo, em que A representa renda, B depósito, C pagamento, D garantia e E moradia.



As tabelas de probabilidade associadas são:

$P(A)$	
a	0.30
$\neg a$	0.70

$P(E)$	
e	0.35
$\neg e$	0.65

$P(B \mid A)$	a	$\neg a$
b	0.10	0.60
$\neg b$	0.90	0.40

$P(C \mid A, B)$	(a, b)	$(a, \neg b)$	$(\neg a, b)$	$(\neg a, \neg b)$
c	0.05	0.50	0.45	0.60
$\neg c$	0.95	0.50	0.55	0.40

$P(D \mid C, E)$	(c, e)	$(c, \neg e)$	$(\neg c, e)$	$(\neg c, \neg e)$
d	0.01	0.50	0.75	0.31
$\neg d$	0.99	0.50	0.25	0.69

Se tratássemos cinco variáveis binárias sem explorar a estrutura do problema, uma distribuição conjunta completa poderia exigir muitos parâmetros. Em uma rede Bayesiana, a redução vem das **independências condicionais codificadas pelo grafo**: cada variável precisa ser condicionada apenas aos seus pais.
Pela regra da cadeia,

$$P(a, b, c, d, e) = P(a)P(b \mid a)P(c \mid a, b)P(e \mid a, b, c)P(d \mid a, b, c, e).$$

Para a rede acima, as independências condicionais permitem escrever

$$P(e \mid a, b, c) = P(e), \qquad P(d \mid a, b, c, e) = P(d \mid c, e),$$

e, portanto,

$$\boxed{P(a, b, c, d, e) = P(a)P(b \mid a)P(c \mid a, b)P(e)P(d \mid c, e)}.$$

Calcule o valor numérico de $P(a, b, c, d, e)$ usando as tabelas fornecidas.
Crédito do exemplo: https://www.dataminingapps.com/2019/09/bayesian-networks-lessons-learned-from-the-past/