Dever de casa sobre PCA

Análise de Componentes Principais

Orientações

Neste curso, nas questões sobre PCA, não iremos cobrar o cálculo em si da matriz PCA. O aluno interessado em saber um pouco mais sobre como a PCA é calculada, é convidado a observar o uso de SVD na PCA do scikit-learn (vide [3]) e evoluir daí.

Iremos assumir que temos à nossa disposição, uma rotina em Python, Matlab, etc, que calcula para nós a matriz PCA. Iremos então treinar a interpretação da PCA, por exemplo, evitando o erro comum de se achar que a transformação PCA reduz a dimensionalidade. Sabemos que o correto é pensar que a transformação PCA mantém a dimensionalidade dos dados, mas é comum após a PCA, realizarmos o descarte de alguns parâmetros e essa etapa é que reduz a dimensão dos dados.

Questão 1

Se os dados são X =

1	0
2	0
3	0
5	6
6	6
7	6

use uma rotina de PCA e indique: quais as duas componentes principais? Quais os autovalores e as variâncias associadas com estas duas componentes principais?

Questão 2

Considere 3 pontos de dados em um espaço bidimensional $\mathbb{R}^2$: (-1, 1), (0, 0), (1, 1). Qual é o primeiro (mais importante) componente principal do conjunto de dados fornecido?

Questão 3

Suponha que realizamos PCA em um conjunto de dados bidimensional e o resultado são dois autovalores iguais. Isso pode ocorrer por exemplo no caso dos dados serem: (1, 1), (0, 0), (0, 1) e (1, 0). O que dois autovalores iguais significam em relação à importância de cada dimensão? Buscar uma redução de dimensionalidade seria uma boa escolha neste caso? Explique.

Questão 4

Acompanhe o tutorial em [2] e implemente o código em Python que realiza a PCA em um dataset com mais de 3 parâmetros de entrada (“features”), de forma a converter este dataset em um novo dataset com apenas duas “features”.

Referências

[1] https://blog.xa0.de/post/PCA-by-example-with-exercices-and-solutions/

[2] https://www.datacamp.com/tutorial/principal-component-analysis-in-python

[3] https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html