Universidade Federal do Pará
Instituto de Tecnologia (ITEC)
Faculdade de Engenharia da Computação e Telecomunicações (FCT)

Projeto guiado 1: Classificação de dígitos manuscritos

1 Introdução e objetivo

Este projeto formaliza o desenvolvimento de um sistema de aprendizagem de máquina supervisionada para a classificação de dígitos manuscritos. O objetivo fundamental é construir um classificador capaz de receber uma matriz de entrada $\mathbf{X}$, que representa os pixels de uma imagem composta por N parâmetros, e prever corretamente sua classe correspondente y dentro do conjunto de etiquetas $\{0, 1, \ldots, 9\}$. A partir deste projeto, as equipes irão colocar seus modelos treinados para verificar qual equipe alcançou a melhor acurácia de classificação dos digítos no conjunto de dados de teste.

1.1 Diretrizes gerais

Para este projeto guiado, seguem algumas diretrizes básicas:

- Os alunos devem se dividir em **equipes de até 5 integrantes**.
- No dia da apresentação, será **sorteada** uma pessoa de cada equipe para realizar a apresentação dos resultados.
- O tempo de apresentação para cada equipe será de **6 minutos**. Após isso, serão destinados **5 minutos** para perguntas.
- Discentes que foram sorteados em apresentações de projetos guiados anteriores **não** poderão ser sorteados novamente.
- As equipes devem registrar seus participantes utilizando este documento, disponível no Google Docs. O nome da equipe, o nome e a matrícula de cada participante devem ser informados.

2 O conjunto de dados: estrutura e atributos

Os dados brutos coletados são organizados em formato de tabela, essencial para a manipulação em inteligência computacional. Cada linha da tabela representa uma instância única ou registro de um dígito, enquanto cada coluna atua como um campo ou atributo (*feature*) que descreve as características da imagem.

Para este projeto, será utilizado o conjunto de dados da UCI ML (MNIST). Neste conjunto de dados, cada imagem é definida por uma matriz de 8×8 pixels, que é convertida em um vetor de 64 atributos numéricos. A Tabela 1 ilustra como essa organização estrutural se apresenta, sabendo que esse conjunto de dados de treino possui 1797 instâncias:

Tabela 1: Exemplo de organização de instâncias e atributos no conjunto de dados de dígitos do MNIST.

Instância	**Pixel 1**	**Pixel 2**	...	**Pixel 64**	**Classe** (y)
1	0	0.5	...	0	5
2	0	0.0	...	0.8	0
⋮	⋮	⋮	...	⋮	⋮
1797	0.2	0.9	...	0	4

Os atributos são predominantemente números reais, enquanto a classe final é um número inteiro, indicando o dígito correspondente a imagem.

3 Preparação e requisitos na entrega

Considerando o modelo escolhido e o conjunto de dados mencionados, cada equipe deve projetar seus respectivos modelos, considerando que 80% do conjunto de dados disponibilizado será utilizado para treino e os 20% restantes para teste. A divisão do conjunto de dados consta no template do notebook jupyter. Desse modo, **as equipes não devem alterar a forma como essa divisão foi feita, por exemplo, modificando a semente (seed) utilizada na divisão**. Seguindo essa diretriz inicial, as equipes devem entregar os seguintes resultados:

- **RQ1**: O conjunto de dados (treino e teste) deve ser normalizado utilizando algum método de normalização, tais como z-score ou normalização min-max.
- **RQ2**: A equipe deve mostrar a matriz de confusão do desempenho do modelo escolhido nos conjuntos de dados de treino e teste.
- **RQ3**: A equipe deve fornecer um gráfico de barras contendo as seguintes métricas de desempenho: acurácia, precisão e recall.
- **RQ4**: A equipe deve fornecer um gráfico em linha contendo a curva ROC e o valor da AUC.

4 Regras

Para este projeto, haverá dois tipos de avaliação:

- Uma avaliação deve levar em consideração o conhecimento e o domínio da equipe na apresentação da solução proposta, tanto durante a apresentação quanto na avaliação do notebook Jupyter entregue. Os pontos para essa avaliação serão de **0 a 10**.
- Uma segunda avaliação, **valendo pontuação extra**, levará em conta a competição do melhor modelo obtido entre as equipes.

4.1 Regras para a avaliação sobre o domínio do assunto

- O entregável deverá ser um notebook Jupyter no formato `.ipynb`, contendo a solução proposta pela equipe.
- Cada equipe será responsável por desenvolver um notebook Jupyter, detalhando todas as etapas de desenvolvimento, desde a manipulação dos dados até a análise final de desempenho. O notebook Jupyter deve seguir o template disponibilizado neste link.
- Cada equipe deve selecionar um dos modelos de classificação apresentados em sala para a aplicação no projeto. Os modelos permitidos para este projeto são: **SVM**, **árvores de decisão**, **k-NN** e **random forest** , ou a mescla desses modelos utilizando **ensemble learning**.
- A entrega deverá ser feita exclusivamente pelo SIGAA. O prazo para entrega é **13/04/2026** até às **23h59**.

4.2 Regras para a competição

Após a entrega de todos os notebooks Jupyter, será feito um ranqueamento das melhores soluções, levando em consideração a métrica de acurácia no conjunto de teste. Nesse sentido, algumas regras devem ser observadas:

- Não é permitida a alteração da seed utilizada na divisão do conjunto de dados. Havendo alterações nesse parâmetro, a equipe ficará com zero pontos na tabela de classificação da competição.
- Não é permitido o uso de modelos além dos listados na subseção 4.1. Por exemplo, não é permitido o uso de redes neurais. Havendo uso, a equipe ficará com zero pontos na tabela de classificação da competição.

- Se duas ou mais equipes atingirem o mesmo valor de acurácia no conjunto de teste, o critério de desempate será a data/hora de envio no SIGAA. A equipe que realizar o envio mais rápido ganhará.
- Os pontos obtidos nesta competição seguirão para os próximos projetos guiados.