



Projeto guiado 3: Avaliação de Sistemas RAG com LLMs

1 Introdução e objetivo

Este projeto formaliza o desenvolvimento e a avaliação de um sistema de Geração Aumentada por Recuperação (*Retrieval-Augmented Generation* - RAG) utilizando Modelos de Linguagem Grandes (LLMs). O objetivo fundamental é construir um pipeline capaz de receber uma pergunta de múltipla escolha, buscar o contexto relevante em um banco de dados vetorial construído a partir de artigos da Wikipedia e fornecer esse contexto ao LLM para que ele preveja corretamente a alternativa da questão. A partir deste projeto, as equipes irão comparar a acurácia do modelo isolado (*Zero-Shot Baseline*) contra o modelo equipado com o sistema RAG em diferentes disciplinas de conhecimento textual e factual.

1.1 Diretrizes gerais

Para este projeto guiado, seguem algumas diretrizes básicas:

- Os alunos devem se dividir em **equipes de até 5 integrantes**.
- Cada equipe ficará responsável por uma disciplina específica focada em conhecimento textual (ex: *Computer Security, virology, Marketing, professional law, High School World History, nutrition, public relations*).
- Para padronizar cada dataset deve conter 100 questões e pode ser baixado diretamente ou neste link.
- No dia da apresentação, será **sorteada** uma pessoa de cada equipe para realizar a apresentação dos resultados.
- O tempo de apresentação para cada equipe será de **6 minutos**. Após isso, serão destinados **5 minutos** para perguntas.
- Discentes que foram sorteados em apresentações de projetos guiados anteriores **não** poderão ser sorteados novamente.
- As equipes devem registrar seus participantes utilizando este documento, disponível no Google Docs. O nome da equipe, a disciplina alocada, o nome e a matrícula de cada participante devem ser informados.

2 O conjunto de dados: estrutura e atributos

Para a avaliação dos modelos de linguagem, será utilizado o renomado *dataset* **MMLU** (Massive Multitask Language Understanding) disponibilizado no Hugging Face. Este conjunto de dados é estritamente textual, focado em perguntas de múltipla escolha com 4 alternativas. A Tabela 1 ilustra a organização estrutural de uma instância deste *dataset*:

A classe final (*answer*) é representada por um número inteiro (0 a 3), correspondendo às letras A, B, C e D.

Tabela 1: Exemplo de organização de instâncias no conjunto de dados MMLU.

Instância	Pergunta (<i>Question</i>)	Alternativas (<i>Choices</i>)	Resposta (<i>y</i>)
1	What is a common objective of a DoS attack?	[A) Data theft, B) Service disruption, C) Privilege escalation, D) Code execution]	1 (Letra B)

3 Preparação e requisitos na entrega

Cada equipe deve projetar sua base de conhecimento vetorial e testar o LLM sobre o *split* de teste da disciplina que lhe foi designada no MMLU. O modelo de linguagem a ser utilizado OBRIGATORIAMENTE é o Qwen/Qwen2.5-0.5B-Instruct, garantindo que todas as equipes tenham a mesma restrição de capacidade de inferência, e o modelo de *embeddings* deve ser o BAAI/bge-small-en-v1.5. Seguindo essas diretrizes, as equipes devem entregar os seguintes resultados no *notebook*:

- **RQ1 (Construção do Corpus):** A equipe deve extrair documentos relevantes relacionados ao seu tema, aplicar um método de divisão de textos (*chunking*) adequado e inseri-los em um banco vetorial.
- **RQ2 (Avaliação Zero-Shot):** A equipe deve avaliar o desempenho do LLM (Qwen 0.5B) no *dataset* da sua disciplina **sem** o auxílio do RAG, obtendo a acurácia base (*Baseline*).
- **RQ3 (Avaliação RAG):** A equipe deve implementar a recuperação do contexto e medir a nova acurácia obtida pelo modelo com o auxílio do RAG.
- **RQ4 (Análise Gráfica):** A equipe deve fornecer um gráfico comparando os acertos absolutos e a acurácia percentual entre os cenários *Baseline* e RAG, e discutir os resultados observados durante a implementação.

4 Regras

Para este projeto, haverá dois tipos de avaliação:

- Uma avaliação deve levar em consideração o conhecimento e o domínio da equipe na apresentação da solução proposta, tanto durante a apresentação quanto na avaliação do notebook Jupyter entregue. Os pontos para essa avaliação serão de **0 a 10**.
- Uma segunda avaliação, **valendo pontuação extra**, levará em conta a competição do maior ganho de desempenho gerado pelo sistema RAG de cada equipe.

4.1 Regras para a avaliação sobre o domínio do assunto

- O entregável deverá ser um notebook Jupyter no formato `.ipynb`, contendo a solução proposta pela equipe.
- Cada equipe será responsável por detalhar todas as etapas de desenvolvimento: extração de dados dos documentos, *chunking*, geração de vetores, recuperação semântica e inferência com o LLM.
- O notebook Jupyter deve seguir o padrão e estrutura abordados nos laboratórios em sala de aula.
- A entrega deverá ser feita exclusivamente pelo SIGAA. O prazo para entrega é **14/07/2026 até às 23h59**.

4.2 Regras para a competição

Após a entrega de todos os notebooks Jupyter, será feito um ranqueamento das melhores soluções. Como cada equipe lidará com uma disciplina e um *dataset* diferentes, a métrica avaliada será o **Delta de Acurácia** (Ganho de Pontos Percentuais em relação ao modelo *Baseline*). Nesse sentido, algumas regras devem ser observadas:

- A fórmula avaliada será: $\Delta = Acurácia_{RAG} - Acurácia_{Baseline}$.
- Não é permitido o uso de um Modelo de Linguagem ou de Embeddings diferente dos listados na Seção 3. Havendo uso de LLMs maiores para manipular os resultados, a equipe ficará com zero pontos na tabela de classificação da competição.
- Se duas ou mais equipes atingirem o mesmo valor de ganho percentual, o critério de desempate será a data/hora de envio no SIGAA. A equipe que realizar o envio mais rápido ganhará.
- Os pontos obtidos nesta competição seguirão para a nota final da disciplina.