Universidade Federal do Pará
Instituto de Tecnologia (ITEC)
Faculdade de Engenharia da Computação e Telecomunicações (FCT)

Inteligência Computacional: 1ª Avaliação (Resolução)

1) O coordenador de projeto pediu-lhe para obter um classificador avaliando um conjunto de 640 configurações de hiperparâmetros, através de validação cruzada de $K = 5$ *folds*. Levando-se em conta que o treinamento de um único modelo deste classificador demora 1 hora. Pede-se: **a)** quantos modelos serão treinados no total e **b)** qual será a duração total desta tarefa de seleção de modelo em dias?

Resolução

a) Nº de modelos = 640 configurações × 5 *folds* = 3200 modelos

b) Duração $= \dfrac{3200 \text{ modelos} \times 1 \text{ hora/modelo}}{24 \text{ horas/dia}} \approx 133,33$ dias

2) Dado o conjunto de treino da tabela abaixo, projete uma árvore de decisão com profundidade máxima 2 (ou seja, no máximo 4 folhas) e, como medida de impureza, o critério de Gini $G_k = 1 - \sum_{i=1}^{C} p_i^2$, k é o nó, p_i é a probabilidade da classe i e C é o número total de classes.

#	x_1	x_2	y
1	12	3.2	0
2	10	0.5	1
3	14	2.8	0
4	14	2.4	0
5	13	1.8	1
6	13	1.5	0
7	11	1	1

Resolução

O objetivo da questão é selecionar a divisão que minimiza a função de custo da árvore, dada por:

$$J(k, t_k) = \frac{m_{esq}}{m} G_{esq} + \frac{m_{dir}}{m} G_{dir}$$

Organizando a tabela em ordem crescente da coluna x_1, tem-se:

#	x_1	x_2	y
2	10	0.5	1
7	11	1	1
1	12	3.2	0
4	13	1.5	0
5	13	1.8	1
4	14	2.4	0
3	14	2.8	0

Deve-se então dividir a tabela escolhendo um limiar entre os dois exemplos e calcular o custo $J(k, t_k)$ correspondente. A decisão escolhida para criar a árvore será a que retornar o menor valor de $J(k, t_k)$. Para **primeira possibilidade**, escolhe-se o limiar entre os dois primeiros exemplos:

#	x_1	x_2	y
2	10	0.5	1
7	11	1	1
1	12	3.2	0
4	13	1.5	0
5	13	1.8	1
4	14	2.4	0
3	14	2.8	0

O limiar dessa divisão será $t_1 = \dfrac{10+11}{2} = 10.5$, a distrbuição será $[0, 1]$ no nó esquerdo e $[4, 2]$ no nó direito. O custo será:

$$J(1, 10.5) = \frac{1}{7}\left(1 - \left(\frac{1}{1}\right)^2\right) + \frac{6}{7}\left(1 - \left(\frac{4}{6}\right)^2 - \left(\frac{2}{6}\right)^2\right) = 0.3809$$

Para a **segunda possibilidade**, escolhe-se o limiar entre o segundo e o terceiro exemplos:

#	x_1	x_2	y
2	10	0.5	1
7	11	1	1
1	12	3.2	0
4	13	1.5	0
5	13	1.8	1
4	14	2.4	0
3	14	2.8	0

O limiar dessa decisão será $t_1 = \dfrac{11+12}{2} = 11.5$, e a decisão resultará na distribuição $[0, 2]$ no nó esquerdo e $[4, 1]$ no nó direito. O custo será dado por:

$$J(1, 11.5) = \frac{2}{7}\left(1 - \left(\frac{2}{2}\right)^2\right) + \frac{5}{7}\left(1 - \left(\frac{4}{5}\right)^2 - \left(\frac{1}{5}\right)^2\right) = 0.2285$$

Para a **terceira possibilidade**, escolhe-se o limiar entre o segundo e o terceiro exemplos:

#	x_1	x_2	y
2	10	0.5	1
7	11	1	1
1	12	3.2	0
4	13	1.5	0
5	13	1.8	1
4	14	2.4	0
3	14	2.8	0

O limiar dessa decisão será $t_1 = \dfrac{12+13}{2} = 12.5$, e a decisão resultará na distribuição $[1, 2]$ no nó esquerdo e $[3, 1]$ no nó direito. O custo será dado por:

$$J(1, 12.5) = \frac{3}{7}\left(1 - \left(\frac{1}{3}\right)^2 - \left(\frac{2}{3}\right)^2\right) + \frac{4}{7}\left(1 - \left(\frac{3}{4}\right)^2 - \left(\frac{1}{4}\right)^2\right) = 0.4047$$

Para a **quarta possibilidade**, escolhe-se o limiar entre o quinto e o sexto exemplos, pois como o quarto e o quinto exemplos possuem o mesmo valor, não há como separá-los com um limiar único. Logo, tem-se::

#	x_1	x_2	y
2	10	0.5	1
7	11	1	1
1	12	3.2	0
4	13	1.5	0
5	13	1.8	1
4	14	2.4	0
3	14	2.8	0

O limiar dessa decisão será $t_1 = \dfrac{13+14}{2} = 13.5$, e a decisão resultará na distribuição $[2, 3]$ no nó esquerdo e $[2, 0]$ no nó direito. O custo será dado por:

$$J(1, 11.5) = \frac{5}{7}\left(1 - \left(\frac{2}{5}\right)^2 - \left(\frac{3}{5}\right)^2\right) + \frac{2}{7}\left(1 - \left(\frac{2}{2}\right)^2\right) = 0.3428$$

Como os dois últimos exemplos possuem o mesmo valor em x_1, não há como criar um limiar entre eles. Assim, para continuar a analisar as possibilidades de decisão, ordena-se a tabela em ordem crescente dos valores de x_2 e tem-se:

#	x_1	x_2	y
2	10	0.5	1
7	11	1	1
1	13	1.5	0
4	13	1.8	1
5	14	2.4	0
4	14	2.8	0
3	12	3.2	0

Para a **quinta possibilidade** de decisão, escolhe-se então o limiar entre os dois primeiros exemplos dessa nova tabela e tem-se:

#	x_1	x_2	y
2	10	0.5	1
7	11	1	1
1	13	1.5	0
4	13	1.8	1
5	14	2.4	0
4	14	2.8	0
3	12	3.2	0

O limiar dessa decisão será $t_2 = \dfrac{0.5+1}{2} = 0.75$ e a decisão resultará na distribuição $[0, 1]$ no nó esquerdo e $[2, 4]$ no nó direito. Como essa é mesma distribuição do limiar $t_1 = 10.5$, conclui-se que as duas decisões possuem a mesma função de custo. Ou seja, $J(1, 10.5) = J(2, 0.75) = 0.3809$.

Para a **sexta possibilidade** de decisão, escolhe-se então o limiar entre o segundo e terceiro exemplos dessa nova tabela e tem-se:

#	x_1	x_2	y
2	10	0.5	1
7	11	1	1
1	13	1.5	0
4	13	1.8	1
5	14	2.4	0
4	14	2.8	0
3	12	3.2	0

O limiar dessa decisão será $t_2 = \dfrac{1+1.5}{2} = 1.25$ e a decisão resultará na distribuição $[0, 2]$ no nó esquerdo e $[4, 1]$ no nó direito. Como essa é mesma distribuição do limiar $t_1 = 11.5$, conclui-se que as duas decisões possuem a mesma função de custo. Ou seja, $J(1, 11.5) = J(2, 1.25) = 0.2285$.

Para a **sétima possibilidade** de decisão, escolhe-se então o limiar entre o terceiro e quarto exemplos dessa nova tabela e tem-se:

#	x_1	x_2	y
2	10	0.5	1
7	11	1	1
1	13	1.5	0
4	13	1.8	1
5	14	2.4	0
4	14	2.8	0
3	12	3.2	0

O limiar dessa decisão será $t_2 = \dfrac{1.5+1.8}{2} = 1.65$ e a decisão resultará na distribuição $[1, 2]$ no nó esquerdo e $[3, 1]$ no nó direito. Como essa é mesma distribuição do limiar $t_1 = 12.5$, conclui-se que as duas decisões possuem a mesma função de custo. Ou seja, $J(1, 12.5) = J(2, 1.65) = 0.4047$.

Para a **oitava possibilidade** de decisão, escolhe-se então o limiar entre o terceiro e quarto exemplos dessa nova tabela e tem-se:

#	x_1	x_2	y
2	10	0.5	1
7	11	1	1
1	13	1.5	0
4	13	1.8	1
5	14	2.4	0
4	14	2.8	0
3	12	3.2	0

O limiar dessa decisão será $t_2 = \dfrac{1.8+2.4}{2} = 2.1$ e a decisão resultará na distribuição $[1, 3]$ no nó esquerdo e $[3, 0]$ no nó direito. O custo será dado por:

$$J(2, 2.1) = \frac{4}{7}\left(1 - \left(\frac{1}{4}\right)^2 - \left(\frac{3}{4}\right)^2\right) + \frac{3}{7}\left(1 - \left(\frac{3}{3}\right)^2\right) = 0.2142$$

O qual é o menor custo até então. Analisando as possibilidades restantes, conclui-se que $t_2 = 2.1$ é a decisão com menor custo e portanto a decissão correta para montar a árvore. Analisando

agora os nós de profundidade 1, nota-se que o nó direito não pode mais se divir, pois já está puro ($Gini = 0$). Logo, avalia-se apenas o nó esquerdo. Analisando os dados restantes, tem-se:

#	x_1	x_2	y
2	10	0.5	1
7	11	1	1
1	13	1.5	0
4	13	1.8	1

Verificando a tabela, é possível identificar que só há 3 formas de dividir os dados, os quais seriam:

(a) Limiar: $t_1 = 10.5$ ou $t_2 = 0.75$

#	x_1	x_2	y
2	10	0.5	1
7	11	1	1
1	13	1.5	0
4	13	1.8	1

(b) Limiar: $t_1 = 12$ ou $t_2 = 1.25$

#	x_1	x_2	y
2	10	0.5	1
7	11	1	1
1	13	1.5	0
4	13	1.8	1

(c) Limiar: $t_2 = 1.65$

#	x_1	x_2	y
2	10	0.5	1
7	11	1	1
1	13	1.5	0
4	13	1.8	1

Como as duas colunas já estão ordenadas, é possível calcular o custo para as duas simulataneamente. Assim, tem-se que o custo de cada limiar será:

$$J(1, 10.5) = J(2, 0.75) = \frac{1}{4}\left(1 - \left(\frac{1}{1}\right)^2\right) + \frac{3}{4}\left(1 - \left(\frac{1}{3}\right)^2 - \left(\frac{2}{3}\right)^2\right) = 0.3333$$

$$J(1, 12) = J(2, 1.25) = \frac{2}{4}\left(1 - \left(\frac{2}{2}\right)^2\right) + \frac{2}{4}\left(1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2\right) = 0.25$$

$$J(2, 1.65) = \frac{3}{4}\left(1 - \left(\frac{1}{3}\right)^2 - \left(\frac{2}{3}\right)^2\right) + \frac{1}{4}\left(1 - \left(\frac{1}{1}\right)^2\right) = 0.3333$$

Assim, a decisão com menor custo é $x_1 \leq 12$ (ou $x_2 \leq 1.25$). O que leva resulta na distribuição $[0, 2]$ no nó esquerdo e $[1, 1]$ no nó direito. Apesar de nem todos os nós terem medida de impureza nula, o enunciado estipula profundidade máxima 2, logo a árvore encerra aqui. Desenhando a árvore, tem-se:

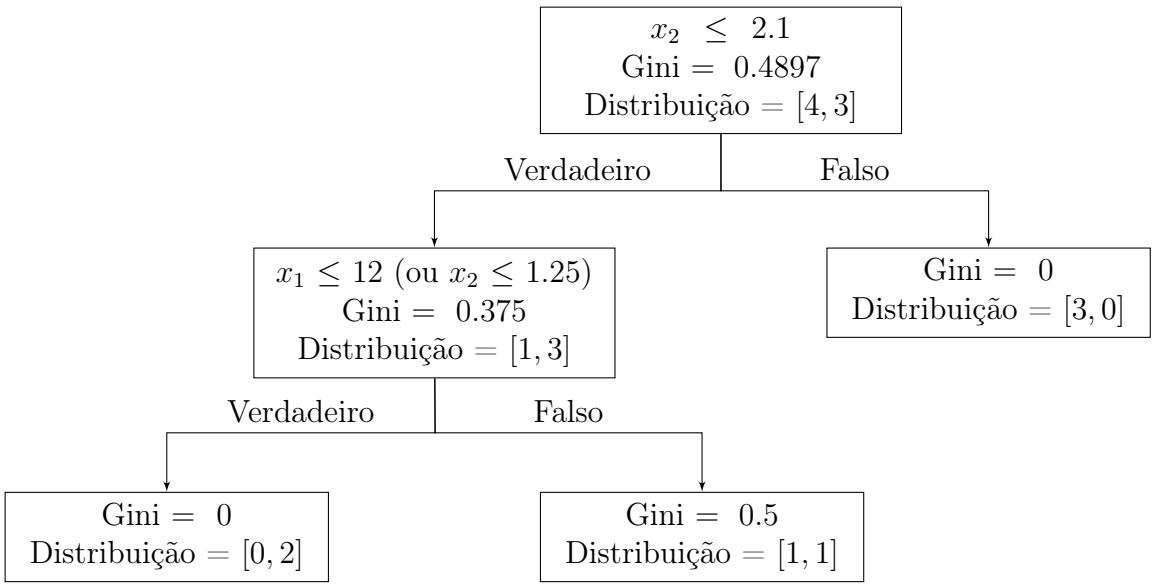

3) A tabela abaixo indica 6 amostras de dados coletados em um estudo sobre fios de determinada liga metálica realizado por uma empresa do ramo metalúrgico. No estudo, foram catalogados a resistência à tração y, medida em kg, e o diâmetro x, medido em unidades de 0.1 mm. Projete um modelo de regressão linear que relacione a resistência em função do diâmetro e estime o erro quadrático médio (**MSE**) do modelo no conjunto de treino.

#	1	2	3	4	5	6
y	15	10	15	25	25	30
x	5	5	6	8	8	10

Resolução

Considerando a equação do modelo de regressão linear, dado por:

$$y = \theta_0 + \theta_1 x$$

A tabela pode ser representada pela seguinte equação matricial:

$$\begin{bmatrix} 15 \\ 10 \\ 15 \\ 25 \\ 25 \\ 30 \end{bmatrix} = \begin{bmatrix} 1 & 5 \\ 1 & 5 \\ 1 & 6 \\ 1 & 8 \\ 1 & 8 \\ 1 & 10 \end{bmatrix} \begin{bmatrix} \theta_0 \\ \theta_1 \end{bmatrix}$$

Utilizando a equação normal, tem-se que os valores ótimos de θ são dados por:

$$\theta = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

Substituindo os valores de $\mathbf{X}$, tem-se:

$$\theta = \left(\begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 \\ 5 & 5 & 6 & 8 & 8 & 10 \end{bmatrix} \begin{bmatrix} 1 & 5 \\ 1 & 5 \\ 1 & 6 \\ 1 & 8 \\ 1 & 8 \\ 1 & 10 \end{bmatrix} \right)^{-1} \begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 \\ 5 & 5 & 6 & 8 & 8 & 10 \end{bmatrix} \begin{bmatrix} 15 \\ 10 \\ 15 \\ 25 \\ 25 \\ 30 \end{bmatrix}$$

$$\theta = \left(\begin{bmatrix} 6 & 42 \\ 42 & 314 \end{bmatrix} \right)^{-1} \begin{bmatrix} 120 \\ 915 \end{bmatrix}$$

$$\theta = \begin{bmatrix} 2.616 & -0.35 \\ -0.35 & 0.05 \end{bmatrix} \begin{bmatrix} 120 \\ 915 \end{bmatrix} = \begin{bmatrix} -6.25 \\ 3.75 \end{bmatrix}$$

Logo, o modelo de regressão linear será dado por $y = -6.25 + 3.75x$. Para calcular o MSE no conjunto de treino, primeiro calculam-se as estimativas do modelo ($\hat{y}$) para os exemplos da tabela.

$$\hat{y_1} = \theta_0 + \theta_1(x_1) = -6.25 + 3.75(5) = 12.5$$
$$\hat{y_2} = \theta_0 + \theta_1(x_2) = -6.25 + 3.75(5) = 12.5$$
$$\hat{y_3} = \theta_0 + \theta_1(x_3) = -6.25 + 3.75(6) = 16.25$$
$$\hat{y_4} = \theta_0 + \theta_1(x_4) = -6.25 + 3.75(8) = 23.75$$
$$\hat{y_5} = \theta_0 + \theta_1(x_5) = -6.25 + 3.75(8) = 23.75$$
$$\hat{y_6} = \theta_0 + \theta_1(x_6) = -6.25 + 3.75(10) = 31.25$$

Assim, o MSE será dado por:

$$MSE = \frac{1}{N} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

$$MSE = \frac{1}{6} \left[(15 - 12.5)^2 + (10 - 12.5)^2 + (15 - 16.25)^2 + (25 - 23.75)^2 + (25 - 23.75)^2 + (30 - 31.25)^2 \right]$$

$$MSE = 3.125$$

4) Considerando o conjunto de treino da Tabela 2a (na próxima página) com quatro instâncias, cada uma definida por um vetor de entrada $\mathbf{x}_i \in \mathbb{R}^3$ de atributos e y uma variável categórica de tal modo que $\{\mathrm{A}, \mathrm{B}\} \in y$ representa a classe associada à instância. Projete um classificador *k-nearest neighbor* com $k = 2$, e classifique as três instâncias do conjunto de teste, definido na Tabela 2b, considerando a distância **Euclidiana**. Informe a taxa de erro do classificador.

(a) Conjunto de dados para treino da questão 4

#	x_1	x_2	x_3	y
1	2.5	1	3	B
2	1.4	7	2	A
3	-3.2	2	4	A
4	1.4	3	7	B

(b) Conjunto de dados para teste da questão 4

#	x_1	x_2	x_3	$\hat{y}$	y
1	-1.5	-5	1	?	A
2	3.4	2	-6	?	B
3	1.3	2	3	?	B

Resolução

Considerando que o conjunto de teste possui três instâncias, tem-se o cálculo das distâncias para cada instância no conjunto de treino, o respectivo ordenamento decrescente destas e a classe predita pelo classificador:

Para a instância 1:

$$d_{11} = \sqrt{(-1.5-2.5)^2 + (-5-1)^2 + (1-3)^2} = 7.48$$
$$d_{12} = \sqrt{(-1.5-1.4)^2 + (-5-7)^2 + (1-2)^2} = 12.38$$
$$d_{13} = \sqrt{(-1.5-(-3.2))^2 + (-5-2)^2 + (1-4)^2} = 7.80$$
$$d_{14} = \sqrt{(-1.5-1.4)^2 + (-5-3)^2 + (1-7)^2} = 10.41$$

Logo:

$$d_{11} < d_{13} < d_{14} < d_{12}$$

As duas menores distâncias em relação ao ponto de teste são 1 e 3, cujas classes são B e A, respectivamente. Tomando uma escolha aleatória, temos que:

$$\hat{y} = \mathrm{A}$$

Para a instância 2:

$$d_{21} = \sqrt{(3.4-2.5)^2 + (2-1)^2 + (-6-3)^2} = 9.10$$
$$d_{22} = \sqrt{(3.4-1.4)^2 + (2-7)^2 + (-6-2)^2} = 9.64$$
$$d_{23} = \sqrt{(3.4-(-3.2))^2 + (2-2)^2 + (-6-4)^2} = 11.98$$
$$d_{24} = \sqrt{(3.4-1.4)^2 + (2-3)^2 + (-6-7)^2} = 13.19$$

Logo:

$$d_{11} < d_{12} < d_{14} < d_{13}$$

As duas menores distâncias em relação ao ponto de teste são 1 e 2, cujas classes são B e A, respectivamente. Tomando uma escolha aleatória, temos que:

$$\hat{y} = \mathrm{A}$$

Para a instância 3:

$$d_{31} = \sqrt{(1.3-2.5)^2 + (2-1)^2 + (3-3)^2} = 1.56$$
$$d_{32} = \sqrt{(1.3-1.4)^2 + (2-7)^2 + (3-2)^2} = 5.10$$
$$d_{33} = \sqrt{(1.3-(-3.2))^2 + (2-2)^2 + (3-4)^2} = 4.60$$
$$d_{34} = \sqrt{(1.3-1.4)^2 + (2-3)^2 + (3-7)^2} = 4.12$$

Logo:

$$d_{11} < d_{14} < d_{13} < d_{12}$$

As duas menores distâncias em relação ao ponto de teste são 1 e 4, cujas classes são B e B, respectivamente. Portanto, a classe predita é:

$$\hat{y} = \text{B}$$

Por fim, a taxa de erro do classificador é igual a:

$$\text{taxa de erro} = \frac{1}{3}.$$

5) Na versão do AdaBoost discutida em sala, na iteração t, o peso $w_{t,i}$ do i-ésimo exemplo é atualizado para uso na próxima iteração $t+1$ como $w_{t+1,i} = w_{t,i}\beta_t^{1-e_i}$. O valor e_i é um indicador de erro, sendo $e_i = 1$ quando o exemplo foi classificado incorretamente na iteração t, e $e_i = 0$ caso contrário. O valor de β_t depende do erro ponderado ϵ_t, sendo dado por $\beta_t = \epsilon_t/(1-\epsilon_t)$. Assume-se que há cinco exemplos, com pesos $[0.1, 0.4, 0.2, 0.1, 0.2]$, e o classificador h_t nesta iteração levou a 2 erros, com os valores de e_i correspondendo a $[0, 0, 1, 1, 0]$, respectivamente. Calcule para este caso: a) ϵ_t, b) β_t e c) os novos pesos $w_{t+1,i}$ já normalizados para somarem 1.

Resolução

a) Como a diferença $y - \hat{y}$ só é não-nula quando há erro, pode-se obter o valor de ϵ_t apenas somando os pesos correspondentes ã erros indicados no vetor de erros $\mathbf{e}$ (terceira e quarta posição). Assim, tem-se:

$\epsilon_t = \sum_i w_{t,i} \left|y_i - \hat{y}_i\right| = 0.2 \times 1 + 0.1 \times 1 = 0.3$

b) $\beta_t = \dfrac{\epsilon_t}{1-\epsilon_t} = \dfrac{0.3}{0.7} = 0.4285$

c) $\mathbf{w_{t+1}} = \mathbf{w_t}\beta^{1-\mathbf{e}} = [0.1 \ \times 0.4285,\ 0.4 \times 0.4285,\ 0.2 \times 0.4285^0,\ 0.1 \times 0.4285^0,\ 0.2 \times 0.4285]$

$$\mathbf{w_{t+1}} = [0.0428,\ 0.1714,\ 0.2,\ 0.1,\ 0.0857]$$

$$\mathbf{w_{t+1}} = \frac{1}{\sum_i w_{t,i}}\mathbf{w_t} = \frac{1}{0.0428 + 0.1714 + 0.2 + 0.1 + 0.0857}[0.0428,\ 0.1714,\ 0.2,\ 0.1,\ 0.0857]$$

$$\mathbf{w_{t+1}} = \frac{1}{0.6}[0.0428,\ 0.1714,\ 0.2,\ 0.1,\ 0.0857] = [0.0714,\ 0.2857,\ 0.3333,\ 0.1666,\ 0.1428]$$

6) Projete uma *decision stump* para ser usada como classificador fraco em uma iteração t do AdaBoost. Neste caso, o i-ésimo exemplo de treino tem um peso w_i associado, indicando sua importância. A *stump* deve minimizar o erro ponderado ϵ_t (que leva em conta os pesos) obtido no conjunto de treino dado por $\mathcal{T} = \{[(-2,3);0], [(-1,7);0], [(2,5);0], [(0,4);1], [(1,6);1]\}$ onde cada exemplo $(\mathbf{x}; y) \in \mathcal{T}$ é composto por um vetor de entrada $\mathbf{x} = (x_1, x_2)$ de dimensão 2 e sua classe $y \in \{0, 1\}$. Na iteração t, os respectivos pesos w_i desses cinco exemplos são $\{0.3, 0.1, 0.4, 0.1, 0.2\}$. Pede-se: **a)** a regra *if-else* correspondente à *stump* projetada e **b)** o erro ϵ_t da mesma.

Resolução
Organizando os dados do enunciado tem-se:

x_1	x_2	y	w_i
-2	3	0	0.3
-1	7	0	0.1
2	5	0	0.4
0	4	1	0.1
1	6	1	0.2

Agora, ordenando os dados em ordem crescente da *feature* x_1, tem-se:

x_1	x_2	y	w_i
-2	3	0	0.3
-1	7	0	0.1
0	4	1	0.1
1	6	1	0.2
2	5	0	0.4

Verificas-se, então, todas as possibiildades de divisão do conjunto de dados e seus respectivos valores de ϵ_t. A *stump* selecionada deve ser a que retorna o menor ϵ_t possível. Para a **primeira possibilidade**, tem-se:

x_1	x_2	y	w_i
-2	3	0	0.3
-1	7	0	0.1
0	4	1	0.1
1	6	1	0.2
2	5	0	0.4

Essa divisão terá duas *stumps* possíveis, sendo a primeira `if` $x_1 \leq -1.5$: $y = 0$; `else`: $y = 1$. Essa *stump* possui ϵ_t igual a:

$$\epsilon_t = 0.3|0-0| + 0.1|0-1| + 0.1|1-1| + 0.2|1-1| + 0.4|0-1| = 0.5$$

A segunda *stump* possível com essa divisão é `if` $x_1 \leq -1.5$: $y = 1$; `else`: $y = 0$. Essa *stump* possui ϵ_t igual a:

$$\epsilon_t = 0.3|0-1| + 0.1|0-0| + 0.1|1-0| + 0.2|1-0| + 0.4|0-0| = 0.6$$

Para a **segunda possibilidade**, tem-se:

x_1	x_2	y	w_i
-2	3	0	0.3
-1	7	0	0.1
0	4	1	0.1
1	6	1	0.2
2	5	0	0.4

Essa divisão terá duas *stumps* possíveis, sendo a primeira `if` $x_1 \leq -0.5$: $y = 0$; `else`: $y = 1$. Essa *stump* possui ϵ_t igual a:

$$\epsilon_t = 0.3|0-0| + 0.1|0-0| + 0.1|1-1| + 0.2|1-1| + 0.4|0-1| = 0.4$$

A segunda *stump* possível com essa divisão é `if` $x_1 \leq -0.5$: $y = 1$; `else`: $y = 0$. Essa *stump* possui ϵ_t igual a:

$$\epsilon_t = 0.3|0-1| + 0.1|0-1| + 0.1|1-0| + 0.2|1-0| + 0.4|0-0| = 0.7$$

Seguindo esses exemplos, avalia-se todos os limiares possíveis para x_1. Agora, ordenando a tabela em ordem crescente de x_2, tem-se:
Analisando agora o limiar entre o terceiro e quarto exemplos, tem-se:

x_1	x_2	y	w_i
-2	3	0	0.3
0	4	1	0.1
2	5	0	0.4
1	6	1	0.2
-1	7	0	0.1

x_1	x_2	y	w_i
-2	3	0	0.3
0	4	1	0.1
2	5	0	0.4
1	6	1	0.2
-1	7	0	0.1

E a *stump* com menor erro possível nesse caso será `if` $x_2 < 5,5$: $y = 0$; `else:` $y = 1$. Nesse caso, o erro ϵ_t será dado por:

$$\epsilon_t = 0.3|0-0| + 0.1|1-0| + 0.4|0-0| + 0.2|1-1| + 0.1|0-1| = 0.1 + 0.1 = 0.2$$

Assim, as respostas são: **a)** `if` $x_2 < 5,5$: $y = 0$; `else:` $y = 1$ e **b)** $\epsilon_t = 0.2$.

7) A entrada de um classificador SVM não-linear consiste no vetor $\mathbf{x} = [x_1, x_2, x_3]$ com três parâmetros. A classe y pode ser 0 ou 1. A função de decisão dessa SVM é dada por $f(\mathbf{x}) = 4\mathcal{K}(\mathbf{x}; [2, -3, 4]) - 5\mathcal{K}(\mathbf{x}; [1, 0, 3]) + 2$. O kernel $\mathcal{K}(\mathbf{x}; \mathbf{z}) =< \mathbf{x}, \mathbf{z} >^2$ é polinomial de ordem 2. Assumindo-se uma entrada $\mathbf{x} = [1, 1, 1]$, quais os valores de: **a)** $f(\mathbf{x})$ e **b)** da classe estimada $\hat{y}$?

Resolução

a) assumindo a função $f(\mathbf{x})$, temos que:

$$f(\mathbf{x}) = 4\mathcal{K}(\mathbf{x}; [2, -3, 4]) - 5\mathcal{K}(\mathbf{x}; [1, 0, 3]) + 2$$

E sabendo que $\mathcal{K}(\mathbf{x}; \mathbf{z})$ é o quadrado do produto interno entre os vetores $\mathbf{x}$ e $\mathbf{z}$, temos que $f(\mathbf{x})$ é igual:

$$f(\mathbf{x}) = 4\times < [1, 1, 1]; [2, -3, 4] >^2 -5\times < [1, 1, 1]; [1, 0, 3] >^2 +2$$

$$f(\mathbf{x}) = 4 \times 3^2 - 5 \times 4^2 + 2$$

$$f(\mathbf{x}) = 36 - 80 + 2$$

$$f(\mathbf{x}) = -42$$

b) Assumindo que para $f(\mathbf{x}) > 0$, a classe predita é igual a 1, e 0 do contrário, temos que $f(\mathbf{x}) = -42 \leq 0$, logo, a classe estimada é 0.

8) Execute uma única iteração de agrupamento com K-Means, adotando-se a distância Euclidiana e $K = 3$. Os dados de entrada consistem em seis vetores bidimensionais armazenados em uma matriz 2×6 dada por $A =$ `numpy.array`([[2, 3, 0, 1, 2, 4], [0, 1, 2, 0, 3, 2]]) em notação do Python. Por exemplo, o primeiro exemplo é $\mathbf{x}_1 = [2, 0]^\top$, enquanto o segundo exemplo é $\mathbf{x}_2 = [3, 1]^\top$. Dado que a distância entre o exemplo i, com $i = 0, 2, \ldots 5$, e a centróide j, com $j = 0, 1$ ou 2, já foi computada e armazenada no elemento $\mathbf{D}[i, j]$ de uma matriz $\mathbf{D} =$ `numpy.array`([[10, 2, 4],[2, 30, 1], [41, 9, 3], [1, 3, 5],[4, 3, 2], [3, 5, 6]]) de dimensão 6×3, quais as novas três centróides?

Resolução
Compondo a matriz $\mathbf{D}$, temos que as menores distâncias estão coloridas em vermelho:

$$\begin{bmatrix} 10 & 2 & 4 \\ 2 & 30 & 1 \\ 41 & 9 & 3 \\ 1 & 3 & 5 \\ 4 & 3 & 2 \\ 3 & 5 & 6 \end{bmatrix}$$

Temos que para o i-ésimo exemplo, a seguinte associação com as três centróides, baseada nas distâncias calculadas. Por exemplo, a menor distância do primeiro ponto de exemplo é igual a 2, que está associada com a centróide 2:

Exemplo	Centróide
1	1
2	2
3	2
4	0
5	2
6	0

Portanto, para o cálculo das próximas centróides:
Centróide 0: Sendo a nova centróide C_0 definida pela média, por coordenada, dos pontos 4 e 6:

$$C_0 = \left(\frac{1+4}{2}, \frac{0+2}{2}\right)$$

$$C_0 = (2.5, 1)$$

Centróide 2: Para essa nova centróide C_1, temos que o ponto será dado pela coordenada do exemplo 1, logo:

$$C_1 = (2, 0)$$

Centróide 3: Sendo a nova centróide C_2 definida pela média, por coordenada, dos pontos 2, 3 e 5:

$$C_2 = \left(\frac{3+0+2}{3}, \frac{1+2+3}{3}\right)$$

$$C_2 = \left(\frac{5}{3}, 2\right)$$

9) Uma base de dados é composta por 5000 exemplos. Cada exemplo é formado por um vetor de entrada $\mathbf{x}$ com dimensão 20 e uma classe y que pode assumir 3 valores: A, B ou C. Adota-se um classificador Naïve Bayes que assume que as *likelihoods* são distribuições Gaussianas. Não se esquecendo das 3 probabilidades *a priori*, qual o número total de parâmetros que precisam ser estimados para esse modelo? Justifique sua resposta.

Resolução

Considerando que as *features* possuem distribuição Gaussiana, deve-se calcular dois parâmetros para cada uma: média e desvio padrão. Sendo 20 features, tem-se um total de $20 \times 2 = 40$ parâmetros a serem calculados. Esse procedimento deve ser repetido para cada classe, logo feito 3 vezes, totalizando $40 \times 3 = 120$ parâmetros. Por fim, incluindo a probabilidade *a priori* de cada uma das 3 classes, tem-se um total de $120 + 3 = 123$ parâmetros.

10) Dado o dataset da tabela abaixo, com 4 exemplos e 3 parâmetros no vetor de entrada $\mathbf{x}'$, deseja-se aplicar PCA para reduzir a dimensão da entrada para apenas 2 parâmetros.

#	x_1	x_2	x_3	Classe y
1	2	3	5	0
2	1	8	3	1
3	7	2	4	0
4	5	4	6	1

A matriz de PCA (com as componentes principais) calculada por SVD é:

$$\mathbf{P} = \begin{bmatrix} 1 & 0 & 3 \\ 2 & 4 & 0 \\ 2 & 1 & -2 \end{bmatrix}.$$

A matriz $\mathbf{P}$ pode ser usada para gerar o vetor $\mathbf{z} = \mathbf{P}\mathbf{x}$, onde $\mathbf{x}$ é o vetor coluna representando um exemplo. Crie uma nova tabela com o novo dataset tendo apenas dois parâmetros de entrada fornecidos por PCA.

Resolução

Considerando a matriz de PCA, $\mathbf{P}$, o primeiro passo é realizar a multiplicação matricial abaixo:

$$\mathbf{z} = \mathbf{P}\mathbf{X}$$

Sabendo que $\mathbf{X}$ é definido por todos os vetores coluna do conjunto de dados mencionados acima. Por exemplo, para a primeira instância, temos o seguinte vetor coluna: $\mathbf{x} = [2, 3, 5]^\top$. Portanto, realizando os cálculos:

$$\mathbf{z} = \begin{bmatrix} 1 & 0 & 3 \\ 2 & 4 & 0 \\ 2 & 1 & -2 \end{bmatrix} \begin{bmatrix} 2 & 1 & 7 & 5 \\ 3 & 8 & 2 & 4 \\ 5 & 3 & 4 & 6 \end{bmatrix}$$

$$\mathbf{z} = \begin{bmatrix} 17 & 10 & 19 & 23 \\ 16 & 34 & 22 & 26 \\ -3 & 4 & 8 & 2 \end{bmatrix}$$

Logo, o conjunto de dados obtido após a multiplicação pela matriz de PCA é:

#	x_1	x_2	x_3	Classe y
1	17	16	-3	0
2	10	34	4	1
3	19	22	8	0
4	23	26	2	1

Por fim, realizando a redução de dimensionalidade, elimina-se o atributo x_3, o qual possui a menor variabilidade dentre os 3 atributos, e tem-se o conjunto de dados resultante:

#	x_1	x_2	Classe y
1	17	16	0
2	10	34	1
3	19	22	0
4	23	26	1