

November 24, 2024

Brief Introduction to SVM

Aldebaro Klautau

Universidade Federal do Pará

LASSE



Classificador moderno: SVM

- Desenvolvida por Vladimir Vapnik e colaboradores
 - Início: década de 60
 - Concepção atual: [Cortes & Vapnik, 1995]
- Importantes ingredientes básicos:
 - Classificadores lineares de *máxima margem*
 - “*Truque do kernel*” para obtenção de classificadores não-lineares

Classificadores lineares (problemas binários)

- $f(\mathbf{x}) = \text{sgn}(\langle \mathbf{x}, \mathbf{w} \rangle + b)$


- $\mathbf{x}, \mathbf{w} \in \mathbb{R}^d$, $f(\mathbf{x}) \in \{-1, +1\}$ e $b \in \mathbb{R}$ ("bias")

- $\langle \mathbf{x}, \mathbf{w} \rangle = \|\mathbf{x}\| \|\mathbf{w}\| \cos \theta = \sum_{n=1}^d x_n w_n$ é o produto interno

- sgn retorna o sinal, com $\text{sgn}(0) = 1$


- $\mathbf{w}$ é um vetor normal ao *hiperplano separador*

Exemplo: $d=2$, $\mathbf{x} = (x_1, x_2)$




Classificadores lineares (cont.)

- $f(\mathbf{x}) = \text{sgn}(\langle \mathbf{x}, \mathbf{w} \rangle + b)$, com $\mathbf{w} = (2, 4)$, $b = -6$



Classes “linearmente separáveis”

■ Perceptron versus SVM



Classificadores lineares são limitados

- Exemplo clássico:
EXOR (ou exclusivo)
- Solução 1:
mapeamento $\Phi(\mathbf{x})$ não-linear
- Ex: $\mathbf{x}=(x_1, x_2)$

$$\Phi(\mathbf{x}) = (x_1^2, x_2^2, \sqrt{2}x_1x_2)$$

- Hiperplano projetado no espaço de dimensão maior (3 neste caso)



$$f(\mathbf{x}) = \text{sgn}(w_1x_1^2 + w_2x_2^2 + w_3\sqrt{2}x_1x_2 + b)$$

- Escolhendo-se $w_1=w_2=1$, $w_3=-(2^{0.5})$ e $b=-0.5$ gera:

$$f(\mathbf{x}) = \text{sgn}(x_1^2 + x_2^2 - 2x_1x_2 - 0.5)$$

Expandir para 3 dimensões resolve, mas:

☹ “Maldição da dimensionalidade”



Solução 2: “Truque do kernel”

- $\mathbf{w}$ é uma combinação de vetores de treinamento

$$\mathbf{w} = \sum_{i=1}^N \lambda_i \mathbf{x}_i$$

- Representação “dual” do classificador

$$f(\mathbf{x}') = \text{sgn}(\langle \mathbf{w}, \mathbf{x}' \rangle + b) = \text{sgn}\left(\sum_{i=1}^N \lambda_i \langle \mathbf{x}_i, \mathbf{x}' \rangle + b\right)$$

- Usando-se mapeamento Φ não linear

$$f(\mathbf{x}') = \text{sgn}\left(\sum_{i=1}^N \lambda_i \langle \Phi(\mathbf{x}_i), \Phi(\mathbf{x}') \rangle + b\right)$$

- Exemplo: EXOR $\Phi(\mathbf{x}) = (x_1^2, x_2^2, \sqrt{2}x_1x_2)$
- Note que não há expansão explícita para dimensão maior:
 $\langle \Phi(\mathbf{x}), \Phi(\mathbf{x}') \rangle = (x_1x'_1)^2 + (x_2x'_2)^2 + 2x_1x_2x'_1x'_2 = \langle \mathbf{x}, \mathbf{x}' \rangle^2$

Solução 2: “Truque do kernel”

- ☺ Não é necessário calcular o mapeamento Φ explicitamente
- ☺ Escapa-se da “maldição da dimensionalidade” (“statistical learning theory”)
- ☺ Algoritmos baseados em produtos internos podem ser “kernelizados”

■ Usando-se mapeamento Φ não linear

$$f(\mathbf{x}') = \text{sgn} \left(\sum_{i=1}^N \lambda_i \langle \Phi(\mathbf{x}_i), \Phi(\mathbf{x}') \rangle + b \right)$$

- Exemplo: EXOR $\Phi(\mathbf{x}) = (x_1^2, x_2^2, \sqrt{2}x_1x_2)$
- Note que não há expansão explícita para dimensão maior:
 $\langle \Phi(\mathbf{x}), \Phi(\mathbf{x}') \rangle = (x_1x'_1)^2 + (x_2x'_2)^2 + 2x_1x_2x'_1x'_2 = \langle \mathbf{x}, \mathbf{x}' \rangle^2$

“Truque do kernel” (cont.)

- Kernel: produto interno no espaço imagem de Φ

$$k(\mathbf{x}', \mathbf{x}_i) = \langle \Phi(\mathbf{x}'), \Phi(\mathbf{x}_i) \rangle$$

- Kernels mais usados:

- Polinomial

$$k(\mathbf{x}', \mathbf{x}_i) = \langle \mathbf{x}', \mathbf{x}_i \rangle^p$$

↖ SVM linear, $p=1$

- Gaussiano

$$k(\mathbf{x}', \mathbf{x}_i) = \exp(-\|\mathbf{x}' - \mathbf{x}_i\|^2 / c)$$

- Vetores de suporte: exemplos $\mathbf{x}_i$ para os quais $\lambda_i \neq 0$

$$f(\mathbf{x}') = \text{sgn} \left(\sum_{i=1}^N \lambda_i k(\mathbf{x}', \mathbf{x}_i) + b \right)$$

SVM não-linear - exemplo

- 2 classes:

 - "círculos" o - mistura de 2 Gaussianas


 - "pontos" ● - mistura de 3 Gaussianas

- SVM com kernel Gaussiano


- Médias marcadas com "x"

- 5 vetores de suporte: —
marcados com círculo extra

- Não "modela", concentra-se nas regiões de decisão




Classificador “support vector machine”



SVM (cont.)


B classificadores binários SVM



Combina decisões $f_1(\mathbf{x}), \dots, f_B(\mathbf{x})$ via matriz ECOC

Classificadores: ANN versus SVM

Rede neural



SVMs

