

Advanced Deep Learning

Cross entropy and related

Prof. Aldebaro Klautau
Universidade Federal do Pará (UFPA)

www.lasse.ufpa.br & www.ppgee.ufpa.br

Entropia

- Shannon entropy


$$H(p) = - \sum_{i=1}^k p(i) \log p(i),$$

- Binary entropy formula

$$H_b(p) = H(p, 1-p) = -p \log p - (1-p) \log(1-p)$$

- ⌚ Pode-se usar qualquer base: log (neperiano), log2 (base 2) ou log10
- ⌚ Assume que há n=2 classes, cada uma com probabilidade $P(x)=1/2$, e base $b=2$. Daí entropia $H(x)=1$ bit

Entropia $H_b(p)$ quando há duas classes apenas e log é na base 2



$$\begin{aligned} H(X) &= - \sum_{i=1}^n P(x_i) \log_b P(x_i) \\ &= - \sum_{i=1}^2 \frac{1}{2} \log_2 \frac{1}{2} \\ &= - \sum_{i=1}^2 \frac{1}{2} \cdot (-1) = 1 \end{aligned}$$

Informação segundo Shannon

Se algo tem probabilidade p , sua informação I é

$$I = \log_2(1/p) \text{ bits}$$


Exemplo:

a) $p = 1/4 \rightarrow$

$$I = \log_2(1/(1/4)) = 2 \text{ bits}$$

b) $p = 1/3 \rightarrow$

$$I = \log_2(1/(1/3)) = 1.585 \text{ bits}$$



```
1 %binary entropy
2 prob=linspace(0,1,10000);
3 information = log2(1 ./ prob); %information per class
4 entropy = prob .* log2(1 ./ prob) + (1-prob) .* log2(1 ./ (1-prob));
5 entropy(isnan(entropy)) = 0; %Entropy
6 plot(prob, entropy)
7 xlabel('probability'), ylabel('binary entropy (bits)')
```

```
gini = 0.168
samples = 54
value = [0, 49, 5]
class = versicolor
```

Coeficiente de Gini ou Entropia?

A medida do *coeficiente* de Gini é aplicada por padrão, mas você pode selecionar a medida de impureza da *entropia* ao configurar o hiperparâmetro *criterion* para “entropy”. O conceito de entropia originou-se na termodinâmica como uma medida da desordem molecular: a entropia aproxima-se de zero quando as moléculas ainda estão paradas e bem ordenadas. Mais tarde, se espalhou em uma ampla variedade de campos do conhecimento, incluindo a *Teoria da Informação* de Shannon, na qual mede o conteúdo médio de informação de uma mensagem:⁴ a entropia é zero quando todas as mensagens são idênticas. No Aprendizado de Máquina, ela é frequentemente utilizada como uma medida do coeficiente: a entropia de um conjunto é zero quando contém instâncias de apenas uma classe. A Equação 6-3 mostra a definição da entropia do *i-ésimo* nó. Por exemplo, o nó esquerdo de profundidade 2 na Figura 6-1 possui uma entropia igual a

$$-\frac{49}{54} \log\left(\frac{49}{54}\right) - \frac{5}{54} \log\left(\frac{5}{54}\right) \approx 0.31$$

Equação 6-3. Entropia

$$H_i = - \sum_{\substack{k=1 \\ p_{i,k} \neq 0}}^n p_{i,k} \log(p_{i,k})$$

```
occ = [0 49 5]; #number of occurrences
prob = occ / sum(occ); %probability of each class
gini = 1 - sum(prob.^2) %gini
gini = 0.16804 %Gini index for this example
information = log(1 ./ prob) %information per class
weighted_information = prob .* information
weighted_information(isnan(weighted_information)) = 0
entropy = sum(weighted_information) %Entropy
entropy = 0.30850 %Entropy for this example
```

Note que $p \log(1/p)$ é zero quando $p=0$

Entropia é usada em treino de árvores como parte do “ganho de informação”



- Entropia (livro do Géron usa log neperiano, mas adotamos abaixo o log na base 2)

$$H(Y) = - \sum_{y \in \mathcal{Y}} p(y) \log_2 p(y)$$

- Entropia condicional

$$H(Y|X_i) = - \sum_{x_i \in \mathcal{X}} p(x_i) \sum_{y \in \mathcal{Y}} p(y|x_i) \log_2 p(y|x_i)$$

- Ganho de informação (“information gain”):
diferença entre entropias do nó pai e filhos

$$I(X_i; Y) = H(Y) - H(Y|X_i)$$


Codificação da saída da rede neural



USP

Cada conexão (seta) corresponde a um parâmetro ou peso que a rede precisa aprender

Exemplo: detecção dos 10 algarismos (dígitos) usando codificação “one-hot”






Loss functions and function activation

1.Binary Classification

NN model

Layers

Activation



y=0.9

error

label

t=1.0

Cross Entropy(CE)




$$L = -\sum t_i \log y_i$$

2.Multiclass Classification

NN model

Layers

Activation



y1=0.2 y2=0.1 y3=0.7

error

label

t1=0.0 t2=0.0 t3=1.0



Mean Squared Error(MSE)

$$L = \frac{1}{2}(t - y)^2$$

3.Regression

NN model

Layers



y=417


error

label

t=520

Output activations and loss functions

Problem	Example of target (p), C=4	Example of output (q)	Loss	Output activation
Multiclass classification	[0, 1, 0, 0] (one-hot)	[0.2, 0.4, 0.1, 0.3]	Categorical cross-entropy	Softmax
Multilabel classification	[1, 0, 0, 1]	[0.9, 0.4, 0.7, 0.8]	Binary cross-entropy	Sigmoid
Multivariate regression	[5.2, -3.1, 2]	[5.1, -2, 3.2]	MSE	Linear



Cross-entropy $L(p, q) = H(p) + D_{KL}(p//q)$ indicates how much two distributions differ. It is applied for each of the C elements of output vector in multilabel classification. $D_{KL}(p//q)$ is the Kullback–Leibler (KL) divergence (also called relative entropy)

https://en.wikipedia.org/wiki/Kullback%E2%80%93Leibler_divergence

Typically, increasing level of difficulty: multiclass classification, multilabel classification, multivariate regression (often solved with C independent multivariable regressors)